

End-to-End ETL Pipeline E-Commerce Orders

Data Engineering Portfolio Project

Presend by
Muhammad Imam Mudin Badali



Dibimbing.id

GitHub
Imammudinn

Tentang Saya

Data Engineer Enthusiast

Mahasiswa Teknologi Informasi dengan minat di bidang Data Engineering, fokus pada Python, SQL, ETL pipeline, dan data pipeline orchestration. Pengalaman meliputi proyek magang Analisis Big Data di PT Kimia Farma, Tbk. (via Rakamin Academy) menggunakan Google BigQuery dan Looker Studio, serta personal project membangun ETL pipeline menggunakan Pandas, Apache Airflow, dan Docker untuk mengolah data CSV menjadi data terstruktur. Setiap proses saya jalankan dengan prinsip akurasi, validitas analisis, dan relevansi terapan dari data mentah hingga insight yang dapat ditindaklanjuti. Terbuka untuk kolaborasi dan peluang baru di bidang Data Engineering.



Problem Statement

Masalah: Data Kotor dari 3 Channel

Bisnis e-commerce menerima data transaksi dari 3 channel:



Mobile App



Website



Marketplace


Data mentah memiliki masalah:

- ✗ 10 baris duplikat
- ✗ 25 missing values (di harga & email)
- ✗ 5 harga negatif
- ✗ 4+ format tanggal berbeda
- ✗ Inkonsistensi teks

- Di dunia nyata, data dari berbagai sumber selalu kotor
- Tanpa pipeline otomatis, data analyst harus manual cleaning setiap hari
- Pipeline ini menyelesaikan semua masalah di atas secara otomatis

Arsitektur Pipeline

Studi Kasus Identitas Visual yang Kompleks



Orchestrated by: Apache Airflow (daily @ 06:00)

- Ini flow end-to-end dari data mentah sampai report
- Yang unik ada validation GATE, kalau data masih kotor, pipeline stop

Step 1: Extract – Kenali Data Kamu

Isi data



raw_orders.csv

- 130 baris, 11 kolom
- Data transaksi Mei–Juli 2024
- 10 produk dari 2 kategori (Elektronik, Furniture)
- 10+ kota di Indonesia

Masalah yang ditemukan:

Masalah	Jumlah
Baris duplikat	10
Missing email	15
Missing harga	5
Harga negatif	5
Format tanggal mixed	4+
Teks tidak standar	Banyak

```
=== CEK MASALAH ===
Duplikasi: 10
Missing values:
order_id      0
product_id    0
product_name  0
kategori      0
quantity      0
total_harga   5
tanggal_order 0
kota          0
channel       0
status        0
customer_email 20
dtype: int64

Harga negatif: 5

Channel unik: <StringArray>
['MARKETPLACE', 'website', 'mobile_app', 'marketplace', 'website',
 'MOBILE_APP']
Length: 6, dtype: str
Kota unik: <StringArray>
[ 'Surabaya', 'Solo', 'Bandung', 'Makassar', 'malang',
 'SURABAYA', 'Yogyakarta', 'Medan', 'Semarang', 'DENPASAR',
 'Jakarta', 'Denpasar', 'MAKASSAR', 'Malang', 'MEDAN',
 'JAKARTA', 'solo', 'medan', 'BANDUNG', 'SOLO',
 'jakarta']
Length: 21, dtype: str
```

	order_id	product_id	product_name	kategori	quantity	total_harga	tanggal_order	kota	channel	status	customer_email
0	ORD-10056	P005	Monitor Samsung 24"	Elektronik	4	NaN	06/05/2024	Surabaya	MARKETPLACE	shipped	customer2@email.com
1	ORD-10041	P005	Monitor Samsung 24"	Elektronik	2	4200000.0	11/07/2024	Solo	website	cancelled	customer28@email.com
2	ORD-10020	P006	Keyboard Mechanical	Elektronik	1	450000.0	2024-05-18	Bandung	website	cancelled	NaN
3	ORD-10032	P001	Laptop ASUS VivoBook	Elektronik	1	7500000.0	Jun 03, 2024	Makassar	mobile_app	completed	customer2@email.com
4	ORD-10116	P002	Mouse Logitech M330	Elektronik	5	1250000.0	2024-06-28 10:51:00	malang	marketplace	completed	customer1@email.com
5	ORD-10057	P004	Kursi Ergonomis	Furniture	3	8400000.0	May 13, 2024	SURABAYA	Website	pending	customer30@email.com
6	ORD-10070	P003	Meja Kerja Minimalis	Furniture	5	6000000.0	Jul 06, 2024	Yogyakarta	MARKETPLACE	shipped	customer12@email.com
7	ORD-10106	P008	Headset Bluetooth	Elektronik	3	1050000.0	Jun 08, 2024	Medan	mobile_app	completed	NaN
8	ORD-10082	P010	Webcam HD 1080p	Elektronik	4	1120000.0	May 22, 2024	Semarang	mobile_app	completed	customer31@email.com
9	ORD-10027	P005	Monitor Samsung 24"	Elektronik	2	4200000.0	2024-07-01 08:32:00	DENPASAR	Website	completed	customer22@email.com

Step 2: Transform

6 Langkah Pembersihan

Isi:

Before —————▶ After

1. HAPUS DUPLIKAT

130 baris —————▶ 120 baris
Mencegah revenue ter-inflate

2. HAPUS HARGA NEGATIF

5 baris error —————▶ Dihapus
Tidak ada skenario bisnis valid

3. ISI MISSING VALUES

Email kosong —————▶ unknown@placeholder.com
Harga kosong —————▶ Median harga (bukan mean!)
Median tidak terpengaruh outlier laptop 15jt

4. STANDARKAN TANGGAL

2024-05-18, Jun 03, 03/06 ▶ datetime64
4+ format → 1 format standar

5. STANDARKAN TEKS

SURABAYA, surabaya —————▶ Surabaya
Website, MARKETPLACE —————▶ website, marketplace
Mencegah groupby pecah jadi grup palsu

6. FEATURE ENGINEERING

Tambah kolom: bulan, kategori_harga
Mempermudah analisis downstream

```
Sebelum: 130 baris
Setelah hapus duplikat: 120 baris
Setelah hapus harga negatif: 110 baris
Missing values setelah fillna: 0
Tipe tanggal: datetime64[us]
Channel setelah standarisasi: <StringArray>
['website', 'mobile_app', 'marketplace']
Length: 3, dtype: str
Kota setelah standarisasi: <StringArray>
[      'Solo',      'Bandung',      'Makassar',      'Malang',      'Surabaya',
      'Yogyakarta',      'Medan',      'Semarang',      'Denpasar',      'Jakarta']
Length: 10, dtype: str
```

```
Distribusi kategori harga:
kategori_harga
sedang      51
besar       49
kecil        10
Name: count, dtype: int64
```

- Ini bagian inti dari pipeline data cleaning
- Setiap langkah punya ALASAN bisnis, bukan asal bersih-bersih
- Saya pilih median bukan mean untuk harga - karena ada outlier laptop 15 juta
- Standarisasi teks penting: tanpa ini, 'SURABAYA' dan 'Surabaya' dihitung 2 kota berbeda


Step 3: Validate

Quality Gate

Sebelum data di-load, harus PASS 5 checks:

- ✓ Tidak ada baris duplikat
- ✓ Tidak ada missing values
- ✓ Tidak ada harga negatif
- ✓ Kolom tanggal bertipe datetime
- ✓ Channel konsisten

- Ini konsep GATE semacam checkpoint sebelum data masuk warehouse
- Di production, data kotor bisa menyebabkan dashboard salah, dan keputusan bisnis salah



```
=== VALIDASI DATA BERSIH ===  
[OK] Tidak ada duplikat  
[OK] Tidak ada missing value  
[OK] Tidak ada harga negatif  
[OK] Tanggal tipe datetime  
[OK] Channel konsisten
```

Hasil: SEMUA LOLOS

Step 4 & 5: Load & Report

Output 1: orders_clean.csv

- 1. 110 baris data bersih (dari 130 mentah)
- 2. 13 kolom (termasuk 2 kolom baru)

Output 2: summary_report.csv

kategori	total_orders	total_revenue	avg_revenue
Elektronik	81	435,18 jt	5,37 jt
Furniture	29	127,35 jt	4,39 jt
Total	110	562,53 jt	

Data bersih disimpan: orders_clean.csv (110 baris)

=== SUMMARY PER KATEGORI ===


	total_orders	total_revenue	avg_revenue
kategori			
Elektronik	81	435180000.0	5372593.0
Furniture	29	127350000.0	4391379.0

Summary disimpan: summary_report.csv

Dari 130 baris mentah menjadi 110 baris bersih
20 baris error dihapus
Revenue total Rp 562,53 juta
didominasi oleh kategori Elektronik

Orchestration (Airflow)

DAG: etl_ecommerce_daily
Schedule: Setiap hari jam 06:00 WIB



Config:

- Retry: 2x per task
 - Retry delay: 1 menit
 - Catchup: False
 - Tags: etl, ecommerce, daily
- Airflow mengatur kapan dan bagaimana urutan pipeline dijalankan
 - Setiap task berjalan sequential, kalau satu gagal, downstream tidak jalan
 - Retry 2x otomatis, menangani error transient tanpa intervensi manual
 - Di production, bisa tambahkan Slack alert untuk failure notification

Error Handling & Monitoring

Skenario Error yang Ditangani:

- 1. FILE TIDAK ADA**
FileNotFoundError, Retry 2x, Alert
- 2. VALIDASI GAGAL**
Pipeline STOP, Data kotor tidak di-load
- 3. TASK ERROR**
Retry 2x dengan delay, Alert jika masih gagal
- 4. SCHEMA BERUBAH**
KeyError, Manual investigation

Monitoring:

- ✓ Airflow UI – semua task hijau = sukses
- ✓ Log file – "[COMPLETED]" di baris terakhir
- ✓ Output file – timestamp hari ini
- ✓ Row count – jumlah baris masuk akal

Summary

Yang Sudah Dikerjakan:

- ✓ ETL pipeline end-to-end (Python + Pandas)
- ✓ 6 langkah data cleaning dengan alasan bisnis
- ✓ Validation gate untuk kualitas data
- ✓ Orchestration dengan Apache Airflow
- ✓ Error handling + retry logic
- ✓ Logging & monitoring

Tech Stack:



Terima Kasih